Inferencia, Cerebro e Identidad: El Cerebro y la Percepción del Yo

Santiago Caballero Rosas[1]✉, Andy Nick Galicia Buendía[1], Zarah Trujillo Salazar[1]

[1]Facultad de Ciencias, UNAM.

github.com/axiomatheou/MensBayesiana

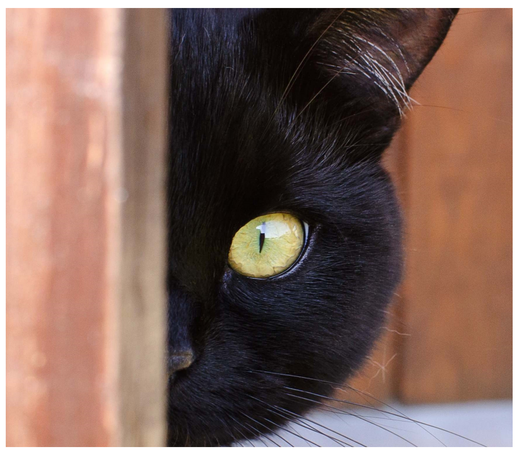

El espejo como paradoja

¿Qué ves realmente cuando te miras al espejo?

Cada mañana, millones de personas realizan el mismo acto sin cuestionarlo: se detienen frente a un espejo, observan su propio rostro y lo reconocen sin esfuerzo aparente. Parece la experiencia más directa e inmediata que existe, pero esta aparente simplicidad esconde uno de los problemas computacionales más profundos que enfrenta el cerebro.

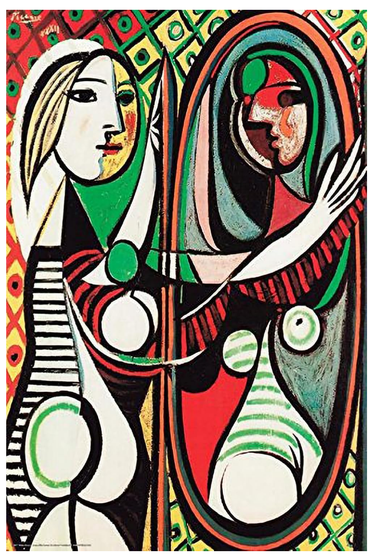

Girl Before a Mirror. Pablo Picasso. 1932. Óleo sobre lienzo. Museum of Modern Art, New York.

El problema geométrico que nadie te enseñó

Cuando la luz proveniente del espejo llega a tus ojos, atraviesa el cristalino y forma una imagen sobre la retina (una superficie *bidimensional* tapizada de fotorreceptores). Ahí ocurre algo con consecuencias profundas: una escena tridimensional queda comprimida en dos dimensiones. Esta compresión no es inocua. Es irreversible, y lo es en un sentido matemático muy preciso: infinitas configuraciones tridimensionales distintas del mundo pueden producir exactamente el mismo patrón de activación retiniana.

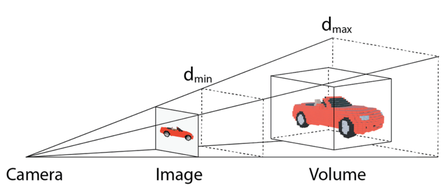

Ejemplo de un problema inverso: una fotografía de un coche. Héctor Costa Guzmán (Licencia CC BY 4.0).

Piénsalo con un ejemplo concreto. Imagina que te permiten ver un automóvil pero únicamente en una fotografía y sólo del lado izquierdo, ¿serías capaz de describir el otro lado del automóvil? ¿Podrías describir cómo es su cofre? El problema es que, la fotografía de un lado del coche podría darnos información imcompleta para reconstruirlo completamente. Los matemáticos llaman a esto un problema inverso mal condicionado: reconstruir la causa a partir del efecto es imposible sin información adicional, porque el mismo efecto puede haber sido producido por causas radicalmente distintas.

Hermann von Helmholtz, fisiólogo y físico del siglo XIX, fue el primero en articular la respuesta correcta. En su monumental *Handbuch der Physiologischen Optik* (1867), propuso que la percepción es inferencia inconsciente: el cerebro no recibe pasivamente la información del mundo... la infiere. Toma la evidencia sensorial incompleta y la combina con todo lo que ya sabe sobre cómo funciona el mundo para construir la interpretación más probable de lo que hay ahí afuera.

El cerebro como máquina de inferencia

La solución: apostar con información

El cerebro convierte la percepción en un problema de inferencia estadística. En lugar de intentar reconstruir el mundo tridimensional a partir de la imagen retiniana, estima cuál estado del mundo es *más probable* dada la evidencia sensorial y todo lo que el organismo ya sabe. La herramienta que formaliza esta operación es el Teorema de Bayes:

$$P(w \mid x) = \frac{P(x \mid w) \cdot P(w)}{P(x)}$$

El **prior** $P(w)$ es el conocimiento acumulado antes de recibir la señal (expectativas construidas por la evolución y por la experiencia individual). La **verosimilitud** $P(x \mid w)$ mide qué tan compatible es la señal recibida con cada hipótesis posible sobre el mundo. El **posterior** $P(w \mid x)$ es el resultado de la inferencia. La nueva creencia sobre el mundo.

El Principio de Energía Libre: navegar hacia Bayes sin calcularlo

Friston (2010) propuso la solución más ambiciosa y unificadora formulada hasta ahora: en lugar de calcular el posterior exacto, el cerebro mantiene una distribución aproximada $q(\vartheta; \mu)$ parametrizada por sus estados internos neuronales μ y la ajusta continuamente para que sea lo más parecida posible al posterior verdadero. La medida de cuán diferente es una distribución de otra es la **divergencia de Kullback-Leibler**, y minimizarla respecto a μ *es* hacer inferencia bayesiana aproximada en tiempo real. Esto es el **Principio de Energía Libre Variacional**:

$$\mu^* = \arg\min_{\mu} \; D_{\mathrm{KL}}(q(\vartheta; \mu) \parallel p(\vartheta \mid \tilde{s}))$$

ϑ son las causas inferidas del mundo, el w de Bayes generalizado. $\tilde{s}$ es la trayectoria sensorial incluyendo sus derivadas temporales, porque el cerebro percibe flujo continuo, no fotogramas aislados. D_{KL} vale exactamente cero solo cuando la creencia del cerebro coincide con el posterior óptimo, algo que en la práctica nunca ocurre del todo, pero hacia lo que el sistema tiende permanentemente.

La elegancia del principio está en lo que evita: el cerebro nunca necesita calcular $P(x)$. En su lugar, minimiza la **energía libre variacional** $\mathcal{F}$, una cota superior tratable de la *sorpresa* del sistema, definida como la improbabilidad de sus propios estados sensoriales bajo su modelo del mundo. Minimizar $\mathcal{F}$ es equivalente a minimizar D_{KL}, pero con la ventaja crucial de que $\mathcal{F}$ puede evaluarse directamente a partir de los estados internos del sistema, sin necesidad de integrar sobre todas las causas posibles.

Dopamina y *Precision Weighting*

Las teorías clásicas del aprendizaje por refuerzo describen a la dopamina como una señal de "error de predicción de recompensa": dispara cuando un evento es mejor de lo esperado, se silencia cuando es peor, y no responde cuando ocurre exactamente como se predijo. Sin embargo, esta descripción resulta incompleta. La dopamina no informa sobre el error de predicción del valor de algo, sino sobre el **valor (la precisión) del error de predicción**.

El **precision weighting** es el mecanismo mediante el cual el cerebro determina cuánta influencia deben tener las señales sensoriales (los errores de predicción) al actualizar nuestras inferencias perceptuales. La dopamina establece el contexto de confianza bajo el cual se forman los perceptos y se inician las acciones: orquesta el equilibrio entre lo que el cerebro espera percibir (*priors*) y la evidencia sensorial.

Ganancia sináptica: el mecanismo neurobiológico

La dopamina ejerce esta función a través de la modulación de la **ganancia sináptica**, la excitabilidad postsináptica de las células piramidales superficiales que transmiten los errores de predicción hacia niveles superiores de la corteza. La dopamina regula la confianza que el cerebro asigna a diferentes señales, modulando el peso relativo entre la información sensorial entrante (bottom-up) y las predicciones generadas internamente (top-down).

Al incrementar la ganancia sináptica de un canal específico, la dopamina otorga relevancia a esa representación sensorial o motora; este aumento es el equivalente neurobiológico exacto de "prestar atención" a un estímulo. La precisión de un error de predicción se codifica directamente modificando esta ganancia, estableciendo el nivel de confianza que el sistema debe depositar en representaciones específicas.

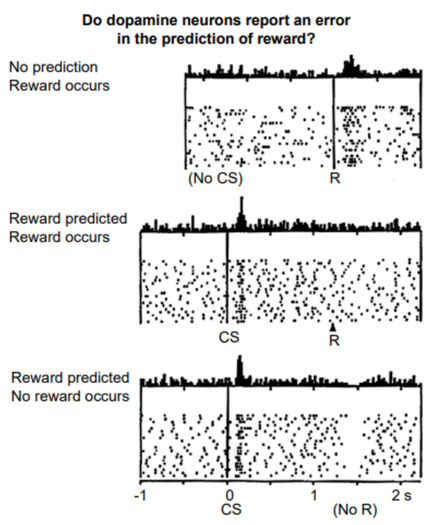

Experimentos de Schultz et al. (1997) con monos registrando neuronas dopaminérgicas del mesencéfalo. Cuando el mono recibe inesperadamente una gota de jugo dulce, las neuronas se activan (error positivo de predicción). Tras aprender que un estímulo anuncia la recompensa, la respuesta neuronal aparece ante el estímulo y ya no ante la recompensa. Si la recompensa esperada no ocurre, la actividad neuronal disminuye en el momento en que debía aparecer.

Los organismos no buscan recompensas en sentido estricto, buscan minimizar la sorpresa (la energía libre) y evitar estados fisiológicos inesperados.

La dopamina señala la precisión de secuencias sensoriomotoras predecibles, ya sean para obtener alimento o para evitar daño:

- **Señal positiva** (aumento de disparos): un evento apetitivo es mejor de lo esperado o no estaba predicho.
- **Señal nula** (actividad basal): la recompensa ocurre exactamente como y cuando se predijo.
- **Señal negativa** (depresión de disparos): una recompensa esperada no se presenta, reduciendo la actividad exactamente en el momento en que debía ocurrir.

Patologías de la máquina de inferencias

El cerebro no solo infiere el mundo externo: también infiere al agente que percibe. Dentro de este sistema, el *self* (el ***yo***) funciona como un modelo generativo del propio cuerpo y del agente, construido a partir de múltiples señales.

Este modelo es altamente estable porque se ha reforzado durante años de experiencia sensorial consistente. En condiciones normales, la evidencia sensorial confirma continuamente el modelo, permitiendo que el cerebro infiera que el cuerpo percibido es el más probable de ser "yo". Es, en este sentido, **el prior más resistente del sistema**: el cerebro lo defiende activamente frente a evidencia contraria.

Sin embargo, cuando la precisión de ciertas señales sensoriales disminuye o ciertos canales dejan de confirmar el modelo, la inferencia puede volverse inestable. A continuación algunos ejemplos:

Efecto espejo (Caputo, 2010)

Fenómeno del espejo descrito por Caputo et al., 2010. Imagen generada con *Nano Banana 2*.

Cuando una persona observa su rostro en un espejo con iluminación tenue durante varios minutos, puede experimentar distorsiones en la percepción de su propio rostro. Caputo (2010) documentó que sujetos sanos reportan caras extrañas, transformaciones faciales o pérdida del reconocimiento del propio rostro bajo estas condiciones. En términos del FEP, la señal visual se vuelve repetitiva y empobrecida (su precisión cae) y la evidencia sensorial que normalmente sostiene el prior del *self* deja de ser suficiente. El modelo generativo del propio rostro pierde su anclaje en la evidencia ascendente y comienza a derivar.

Síndrome de Capgras

En este trastorno, el paciente reconoce visualmente a personas cercanas pero cree que son impostores. Ellis y Young (1990) propusieron que el fenómeno surge por una desconexión entre el reconocimiento visual de rostros y la respuesta emocional de familiaridad: la vía visual está intacta, pero la señal afectiva que normalmente confirma la identidad está ausente. Desde el marco del FEP, esto equivale a un error de precisión selectivo: el canal que pondera la familiaridad emocional pierde su ganancia, y el cerebro, incapaz de reconciliar el rostro conocido con la ausencia de respuesta afectiva esperada, construye la única hipótesis que minimiza la sorpresa... un impostor.

Síndrome de Fregolí

En contraste, los pacientes creen que personas desconocidas son en realidad una misma persona conocida disfrazada. Este fenómeno refleja el proceso inverso: una ponderación de precisión aberrantemente alta sobre señales de familiaridad hace que el sistema las detecte donde no existen, forzando una identidad ilusoria sobre rostros distintos.

References

[1] Giovanni B. Caputo. Strange-face-in-the-mirror illusion. *Perception*, 39(7):1007–1008, 2010.

[2] Hadyn D. Ellis and Andrew W. Young. Accounting for delusional misidentifications. *British Journal of Psychiatry*, 157(2):239–248, 1990.

[3] Karl Friston. The free-energy principle: A unified brain theory? *Nature Reviews Neuroscience*, 11(2):127–138, 2010.

[4] David C. Knill and Alexandre Pouget. The bayesian brain: The role of uncertainty in neural coding and computation. *Trends in Neurosciences*, 27(12):712–719, 2004.

[5] Rajesh P. N. Rao and Dana H. Ballard. Predictive coding in the visual cortex: A functional interpretation of some extra-classical receptive-field effects. *Nature Neuroscience*, 2(1):79–87, 1999.

[6] Anil K. Seth. *Being You: A New Science of Consciousness*. Dutton, 2021.